

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



Machine Learning (CO3117)

Báo Cáo HPMR

Hidden Markov Model

Giáo viên hướng dẫn: TS. Lê Thành Sách

Sinh viên thực hiện: Nguyễn Việt Hoàng 2311066

Nguyễn Chí Thanh 2313078

Lê Đức Tài 2312995

Mai Xuân Nhựt 2312549

THÀNH PHỐ HỒ CHÍ MINH, 05/09/2025

Mục lục

1	Tổng quan	4
2	Hidden Markov Model (HMM)	4
2.1	Định nghĩa HMM	4
2.2	Giải thuật Forward	5
2.3	Giải thuật Backward	6
2.4	Giải thuật Viterbi	7
2.5	Giải thuật huấn luyện tham số Baum-Welch	9
3	Đặc trưng âm học của tiếng nói	15
3.1	Mô hình bộ máy phát âm:	15
3.2	Phân tích MFCC	18
3.2.1	Biến đổi FFT:	18
3.2.2	Biến đổi Fourier ngắn hạn (Short-Time Fourier Transform - STFT) . .	18
3.2.3	Mel-Frequency Cepstral Coefficients (MFCCs):	19
4	Ứng dụng giải thuật	24
4.1	Tổng quan tập dữ liệu và nhiệm vụ của nhóm:	24
4.2	Thống kê mô tả tập dữ liệu:	24
4.3	Huấn luyện mô hình HMM	25
4.3.1	Tập dữ liệu huấn luyện	25
4.3.2	Phương pháp xây dựng mô hình	26
4.3.3	Hiện thực hàm huấn luyện mô hình	27
4.3.4	Hiện thực hàm kiểm tra	28
4.4	Đánh giá mô hình	29
4.5	Kết luận	31
4.5.1	Ưu điểm	31
4.5.2	Nhược điểm	32

1 Tổng quan

Mô hình ẩn Markov (Hidden Markov Model - HMM) là một mô hình thống kê được sử dụng để mô tả các hệ thống mà trạng thái bên trong không thể quan sát trực tiếp, nhưng có thể suy ra thông qua các quan sát bên ngoài. HMM thường được áp dụng trong các lĩnh vực như nhận dạng giọng nói, xử lý ngôn ngữ tự nhiên, sinh học tính toán và nhiều ứng dụng khác.

Trong bài báo cáo này, nhóm sẽ trình bày về các khái niệm cơ bản của HMM, cách xây dựng và huấn luyện mô hình, cũng như các ứng dụng thực tế của nó. Nhóm sẽ sử dụng một tập dữ liệu cụ thể để minh họa quá trình huấn luyện và đánh giá mô hình HMM.

Tập dữ liệu này là bản thu âm các chữ số từ 0 đến 9, được thu thập từ nhiều người nói khác nhau. Mỗi bản ghi âm sẽ được chuyển đổi thành các đặc trưng âm thanh (features) để làm đầu vào cho mô hình HMM. Mục tiêu của chúng tôi là xây dựng một mô hình HMM có khả năng nhận diện chính xác các chữ số dựa trên các đặc trưng này.

Các hiện thực chi tiết và kết quả được trình bày qua [github](#).

2 Hidden Markov Model (HMM)

2.1 Định nghĩa HMM

Về mặt toán học, một Mô hình Markov Ẩn λ là một mô hình sinh (generative model) được định nghĩa bởi một bộ 5 thành phần $\lambda = (Q, V, A, B, \pi)$.

- $Q = \{q_1, q_2, \dots, q_N\}$: Một tập hợp hữu hạn N các **trạng thái ẩn**. Đây là các trạng thái bên trong của hệ thống mà chúng ta không thể quan sát.
- $V = \{v_1, v_2, \dots, v_M\}$ (đôi khi được ký hiệu là σ): Một tập hợp hữu hạn M các **ký hiệu quan sát** (observation symbols) hoặc “phát xạ”. Đây là những gì chúng ta có thể nhìn thấy.
- $A = \{a_{ij}\}$: **Ma trận xác suất chuyển trạng thái** (State Transition Probability Matrix), kích thước $N \times N$.
 - $a_{ij} = P(z_{t+1} = q_j | z_t = q_i)$, với z_t là trạng thái ẩn tại thời điểm t .
 - Đây là xác suất chuyển từ trạng thái q_i sang trạng thái q_j ở bước thời gian tiếp theo.
 - Ràng buộc: $\sum_{j=1}^N a_{ij} = 1$ cho mọi i .

- $B = \{b_j(k)\}$: **Ma trận xác suất phát xạ** (Emission Probability Matrix), kích thước $N \times M$.
 - $b_j(k) = P(x_t = v_k | z_t = q_j)$, với x_t là quan sát tại thời điểm t .
 - Đây là xác suất quan sát được ký hiệu v_k khi (given) hệ thống đang ở trạng thái ẩn q_j .
 - Ràng buộc: $\sum_{k=1}^M b_j(k) = 1$ cho mọi j .
- $\pi = \{\pi_i\}$: **Phân phối xác suất trạng thái ban đầu** (Initial State Probability Distribution), một vector kích thước N .
 - $\pi_i = P(z_1 = q_i)$.
 - Đây là xác suất hệ thống bắt đầu ở trạng thái q_i tại thời điểm $t = 1$.
 - Ràng buộc: $\sum_{i=1}^N \pi_i = 1$.

2.2 Giải thuật Forward

Giải thuật Forward là một phương pháp động (dynamic programming) được sử dụng để tính toán xác suất của một chuỗi quan sát nhất định $P(X|\lambda)$ trong HMM.

Hiện thực:

Tại vì tính toán xác suất nên số liệu rất nhỏ khi qua các bước sẽ gây nên underflow. Do vậy nên code giải thuật sẽ được tính dưới dạng log.

Bước 1: Khởi động - Tính $\alpha_1(i)$, với $i = 1, 2, \dots, N$.

$$\alpha_1(i) = \pi_i b_i(O_1) \quad (2.2)$$

Với hàm $\log_B(O)$ sẽ trả về giá trị xác suất cho 1 cột tương ứng với quan sát O .

```
log_alpha[:, 0] = self.logpi + self.log_B(O[0])
```

Bước 2: Đệ quy - Tính $\alpha_t(i)$, với $t = 2, 3, \dots, T$ và $i = 1, 2, \dots, N$.

$$\alpha_t(i) = \sum_{k=1}^N [\alpha_{t-1}(k) a_{ki}] b_i(O_t) \quad (2.3)$$

Mở rộng 1 cột t của ma trận log alpha $1 \times N \rightarrow N \times N$ qua phép mở rộng chiều và phép cộng để cho các cột của ma trận bằng nhau.

```
for t in range(1, T):
    e = self.log_B(O[t])
    tmp = log_alpha[:, t-1][:, None] + self.logA
    log_alpha[:, t] = logsumexp(tmp, axis=0) + e
```

Với hàm logsumexp giúp tính log tổng của các số.

```
def logsumexp(x, axis=None):
    m = np.max(x, axis=axis, keepdims=True)
    s = m + np.log(np.sum(np.exp(x - m), axis=axis, keepdims=True))
    return np.squeeze(s, axis=axis)
```

Bước 3: Kết thúc - Tính $P(O|\lambda)$

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i) \quad (2.4)$$

```
log_prob = logsumexp(log_alpha[:, T-1])
```

Độ phức tạp: $O(N^2T)$

2.3 Giải thuật Backward

Hiện thực:

Tương tự như giải thuật Forward, ta sẽ tính dưới dạng log để tránh underflow.

Bước 1: Khởi động - $\beta_T(i) = 1$, với $i = 1, 2, \dots, N$.

```
logBeta[:, T-1] = 0.0
```

Bước 2: Đệ quy - Tính $\beta_t(i)$ với

- $t = T - 1, T - 2, \dots, 1$
- $i = 1, 2, \dots, N$

$$\beta_t(i) = \sum_{k=1}^N [a_{ik} b_k(O_{t+1}) \beta_{t+1}(k)] \quad (2.1)$$

Tương như cách tính của Forward

```
for t in range(T-2, -1, -1):
    e_next = self.log_B(O[t+1])
    tmp = self.logA + e_next[None, :] + logBeta[:, t+1][None, :]
    logBeta[:, t] = logsumexp(tmp, axis=1)
```

Độ phức tạp: $O(N^2T)$

2.4 Giải thuật Viterbi

Hiện thực:

Tương tự như giải thuật Forward, ta sẽ tính dưới dạng log để tránh underflow.

Bước 1: Khởi động - Tính $\delta_1(i)$ và $\varphi_1(i)$ theo công thức (3.1) và (3.2), với $i = 1, 2, \dots, N$.

$$\delta_1(i) = \pi_i b_i(O_1) \quad (3.1)$$

$$\varphi_1(i) = 0 \quad (3.2)$$

```

delta = np.full((self.N, T), -np.inf)
phi = np.zeros((self.N, T), dtype=np.int32)
delta[:, 0] = self.logpi + self.log_B(O[0])

```

Bước 2: Đệ quy - Với $t = 2, \dots, T$ và $i = 1, \dots, N$, cập nhật $\delta_t(i)$ và $\phi_t(i)$ theo công thức (3.3) và (3.4).

$$\delta_t(i) = \max_{1 \leq k \leq N} [\delta_{t-1}(k) a_{ki}] b_i(O_t) \quad (3.3)$$

$$\phi_t(i) = \operatorname{argmax}_{1 \leq k \leq N} [\delta_{t-1}(k) a_{ki}] \quad (3.4)$$

Ta sẽ tính như forward và lấy max theo cột.

```

for t in range(1, T):
    e = self.log_B(O[t])
    scores = delta[:, t-1][:, None] + self.logA
    phi[:, t] = np.argmax(scores, axis=0)
    delta[:, t] = np.max(scores, axis=0) + e

```

Bước 3: Kết thúc - Xác định trạng thái tối ưu tại thời điểm T và xác suất tương ứng, dùng công thức (3.5) và (3.6).

$$P^* = \max_{1 \leq k \leq N} \delta_T(k) \quad (3.5)$$

$$q_T^* = \operatorname{argmax}_{1 \leq k \leq N} \delta_T(k) \quad (3.6)$$

```

path = np.zeros(T, dtype=np.int32)
path[T-1] = np.argmax(delta[:, T-1])
log_path_prob = np.max(delta[:, -1])

```


Bước 4: Truy vết ngược - Xác định dãy trạng thái tối ưu dùng Bảng $\varphi_t(i)$ và công thức (3.7). Với $t = T - 1, T - 2, \dots, 1$

$$q_t^* = \varphi_{t+1}(q_{t+1}^*) \quad (3.7)$$

```
for t in range(T-2, -1, -1):  
    path[t] = phi[path[t+1], t+1]
```

Độ phức tạp: $O(N^2T)$

2.5 Giải thuật huấn luyện tham số Baum-Welch

Đối với dạng quan sát, ta sẽ có cách hiện thực khác nhau. Do vậy nhóm sẽ hiện thực HMM dưới dạng 1 class:

class BaseHMM

- **Phương thức khởi tạo** - Nhận vào số trạng thái ẩn N , số quan sát M và khởi tạo các tham số π, A, B ngẫu nhiên.
- **Phương thức log_B(O)** - Nhận vào một quan sát O và trả về xác suất phát xạ dưới dạng log.
- **Phương thức forward(O)** - Thực hiện giải thuật Forward và trả về log xác suất của chuỗi quan sát O .
- **Phương thức backward(O)** - Thực hiện giải thuật Backward và trả về ma trận log beta.
- **Phương thức viterbi(O)** - Thực hiện giải thuật Viterbi và trả về dãy trạng thái tối ưu cùng log xác suất tương ứng.
- **fit(self, data, n_loop=50, bound_learning=1e-4)** - Thực hiện giải thuật Baum-Welch để huấn luyện tham số mô hình dựa trên tập train D .

Hiện thực class này sẽ không cố định việc khởi tạo các ma trận tham số ban đầu là ngẫu nhiên mà sẽ nhận vào các ma trận để người dùng có thể tự config việc sử dụng.

Phân phối xác suất của quan sát O thường có 2 dạng: Catagorical và Gaussian. Do vậy nhóm sẽ kế thừa class BaseHMM để hiện thực 2 class con. Hầu như khác biệt giữa 2 dạng là ở hàm logB và fit vì vậy nên các phương thức còn lại sẽ hiện thực ở lớp basic.

Giải thuật Baum-Welch (EM Algorithm)

Giải thuật Baum-Welch là một thuật toán EM (Expectation-Maximization) được sử dụng để ước lượng các tham số của HMM khi chỉ có chuỗi quan sát O mà không biết chuỗi trạng thái ẩn.

Bước 1: Khởi động - Gán giá trị ngẫu nhiên cho các thông số cần học π , A , B . Lưu ý, từng hàng của ma trận A , B và vector π phải là các phân phối xác suất.

Lặp lại E-step và M-step đến khi hội tụ:

Bước 2: Thực hiện bước tính kỳ vọng (E-step):

- Tính $\alpha_t(i)$ và $\beta_t(i)$ dùng giải thuật lan truyền thuận và ngược ở trên.

Hàm logB

Đối với **discreteHMM**

Trả về 1 cột tương ứng quan sát o_t của ma trận logB.

```
def log_B(self, o_t) -> np.ndarray:  
    return self.logB[:, o_t]
```

Đối với **continueHMM**

Trả về cả 1 ma trận log xác suất của cả chuỗi quan sát O theo 2 tham số mean và covar của mô hình hiện tại.

Xác suất của một quan sát O_t cho D chiều theo phân phối Gaussian đa biến được tính theo công thức:

$$p(O_t|\mu, \sigma) = \frac{1}{(2\pi)^{D/2}|\sigma|^{1/2}} \exp\left(-\frac{1}{2}(O_t - \mu)^T \sigma^{-1}(O_t - \mu)\right)$$

Lấy log:

$$\log p(O_t | \mu, \sigma) = -\frac{D}{2} \log(2\pi) - \frac{1}{2} \log |\sigma| - \frac{1}{2} (O_t - \mu)^T \sigma^{-1} (O_t - \mu)$$

Ta có:

- self._precisions là ma trận nghịch đảo của covar
- np.einsum('ntd,ndk,ntk->nt', diff, self._precisions, diff)

Tính toán $\text{quad}[i, t] = (O_t - \mu_i)^T \Sigma_i^{-1} (O_t - \mu_i)$

- $\log_norm_consts[i] = -\frac{D}{2} \log(2\pi) - \frac{1}{2} \log |\sigma_i|$.

```
def log_B_sequence(self, O: np.ndarray) -> np.ndarray:
    T = O.shape[0]
    diff = O[None, :, :] - self.means[:, None, :]
    quad = np.einsum('ntd,ndk,ntk->nt', diff, self._precisions,
                    diff)
    return self._log_norm_consts[:, None] - 0.5 * quad
```

Tính toán forward và backward:

Tận dụng lại ma trận xác suất phát xạ đã tính ở bước trên để tiết kiệm thời gian tính toán.

```
log_prob, log_alpha, log_b_all = self.forward(O)
logBeta = self.backward(O, log_b_all)
```

- Tính $\xi_t(i, j)$ và $\gamma_t(i)$ theo công thức (4.3) và (4.2).

Biến xi - Xác suất chuyển trạng thái:

Biến $\xi_t(i, j)$ biểu thị xác suất hệ thống ở trạng thái S_i tại thời điểm t và chuyển sang trạng thái S_j tại thời điểm $t + 1$:

$$\xi_t(i, j) = P(q_t = S_i, q_{t+1} = S_j | O, \lambda) \quad (2.2)$$

$$\xi_t(i, j) = \frac{\alpha_t(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(j)}{P(O | \lambda)} \quad (4.3)$$

Trong log-domain:

```
# log_xi: (N, N, T-1)
# tmp[i,j,t] = log_alpha[i,t] + logA[i,j] + log_b[j,t+1] + logBeta[j,t+1]
tmp = (log_alpha[:, :-1].reshape(self.N, 1, T-1) # (N, 1, T-1)
      + self.logA[:, :, None]                    # (N, N, 1)
      + log_b_all[None, :, 1:]                   # (1, N, T-1)
      + logBeta[None, :, 1:])                   # (1, N, T-1)
log_xi = tmp - log_prob
xi = np.exp(log_xi) # (N, N, T-1)
```

Biến gamma - Xác suất trạng thái:

Biến $\gamma_t(i)$ biểu thị xác suất hệ thống ở trạng thái S_i tại thời điểm t , cho trước chuỗi quan sát O và mô hình λ :

$$\gamma_t(i) = P(q_t = S_i | O, \lambda) = \frac{\alpha_t(i)\beta_t(i)}{\sum_{i=1}^N \alpha_t(i)\beta_t(i)} \quad (4.2)$$

Trong log-domain:

```
log_gamma = log_alpha + logBeta - log_prob
gamma = np.exp(log_gamma) # (N, T)
```

Bước 3: Thực hiện bước cực đại hóa kỳ vọng (M-step): Tính π , A , B dùng các công thức (4.5), (4.6), và (4.7).

Cập nhật phân phối ban đầu π :

$$\pi_i = \gamma_1(i) \quad (4.5)$$

```
pi_numerator += gamma[:, 0]
# M-step
self.pi = pi_numerator / len(data)
```

Cập nhật ma trận chuyển trạng thái A :

$$a_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \quad (4.6)$$

```
A_numerator += xi.sum(axis=2)
A_denominator += gamma[:, :-1].sum(axis=1, keepdims=True)
# M-step
self.A = A_numerator / (A_denominator + 1e-12)
```

Cập nhật ma trận phát xạ B :

Đối với **discreteHMM** (quan sát rời rạc):

$$b_j(k) = \frac{\sum_{t=1, O_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)} \quad (4.7)$$

```
B_denominator += gamma.sum(axis=1, keepdims=True)
O_matrix = np.zeros((T, M))
O_matrix[np.arange(T), O] = 1.0 # O_matrix[t, O[t]] = 1
B_numerator += gamma @ O_matrix
# M-step
self.B = B_numerator / (B_denominator + 1e-12)
```

Đối với **continueHMM** (quan sát liên tục - Gaussian):

$$\mu_j = \frac{\sum_{t=1}^T \gamma_t(j) O_t}{\sum_{t=1}^T \gamma_t(j)} \quad (4.8)$$

$$\sigma_j = \frac{\sum_{t=1}^T \gamma_t(j) (O_t - \mu_j)(O_t - \mu_j)^T}{\sum_{t=1}^T \gamma_t(j)} \quad (4.9)$$

```

gamma_sum += gamma.sum(axis=1, keepdims=True)
means_numerator += gamma @ 0 # (N,T) @ (T,D)

# Covariance accumulation using einsum
cov_numerator += np.einsum('nt,td,tk->ndk', gamma, 0, 0)

# M-step: update means and covariances
self.means = np.nan_to_num(means_numerator / (gamma_sum + 1e-12))
S2_term = np.nan_to_num(cov_numerator / (gamma_sum[:, :, None] + 1e-12))
mean_outers = self.means[:, :, None] @ self.means[:, None, :]
self.covariances = S2_term - mean_outers

```

Điều kiện dừng: Thuật toán lặp lại cho đến khi log-likelihood hội tụ:

Với log-likelihood tại mỗi vòng lặp là tổng của log xác suất được trả về từ hàm forward cho tất cả quan sát trong tập train.


$$|LL_{iter} - LL_{iter-1}| < \varepsilon \quad (2.3)$$

Độ phức tạp: $O(N^2T \cdot K)$ với K là số vòng lặp EM.

3 Đặc trưng âm học của tiếng nói

3.1 Mô hình bộ máy phát âm:

Trong mô hình bộ máy phát âm, hệ thống phát âm của con người được xem như một bộ máy tạo ra các tín hiệu âm thanh thông qua sự kết hợp của các thành phần chính: nguồn âm thanh (nguồn rung động từ dây thanh), bộ lọc (hệ thống cộng hưởng của khoang miệng, mũi và họng), và bức xạ (sự phát tán âm thanh ra môi trường bên ngoài). Nguồn âm thanh tạo ra sóng âm cơ bản, sau đó được điều chỉnh và biến đổi bởi bộ lọc để tạo ra các đặc trưng âm học khác nhau.




Source: Atiwong

Hình 3.1: Mô hình bộ máy phát âm

Bức xạ từ bộ lọc ra môi trường bên ngoài có 2 thành phần chính:

- Tần số cơ bản (fundamental frequency - F_0): là tần số dao động cơ bản của dao động dây thanh, tạo ra âm thanh có cao độ (pitch) nhất định. Xấp xỉ 110Hz, 200Hz, 400Hz tương ứng với các giọng nam, nữ và trẻ em.
- Các tần số cộng hưởng formants ($F_1, F_2, F_3, \dots$): là các tần số đặc trưng được tạo ra bởi hệ thống cộng hưởng của bộ lọc khoang miệng, mũi và họng, là thứ quyết định âm sắc. Các tần số này thường có tần số cao hơn với tần số cơ bản F_0 và đóng vai trò quan trọng trong việc xác định đặc trưng âm học của các nguyên âm khác nhau.

Trong phát âm, chúng ta thường có 2 loại âm thanh chính:



Hình 3.2: Âm vô thanh và âm hữu thanh

- Khi phát âm các âm hữu thanh (voiced sounds), dây thanh rung động, tạo ra nguồn dao động có tần số F_0 .
- Khi phát âm các âm vô thanh (unvoiced sounds), dây thanh mở hoàn toàn, không rung động, nguồn dao động chủ yếu là tiếng ồn (noise) được tạo ra từ luồng khí đi qua các hẹp trong khoang miệng do đó các âm này thường có tần số cơ bản F_0 thấp, chủ yếu phân bố âm thanh ở tần số cao. Thường được mô phỏng giống nhau.

Một số ví dụ về các âm sắc khác nhau:

Bảng 3.1: Ví dụ về các âm sắc khác nhau

Trường hợp	Mô tả âm sắc	Đặc trưng phổ (liên quan đến MFCC)
Âm /a/ (mở rộng miệng)	Âm sáng, vang, cộng hưởng mạnh ở tần số thấp (700 Hz)	Formant F1 cao, F2 trung bình
Âm /i/ (miệng hẹp)	Âm sáng, có năng lượng ở tần số cao hơn	F1 thấp, F2 cao
Âm /u/ (tròn môi)	Âm tối, âm	F1 thấp, F2 thấp
Âm /s/ (xì)	Âm sắc gắt, nhiều năng lượng cao tần	Năng lượng tập trung ở 4–8 kHz
Âm /f/ (sh)	Âm sắc “mềm” hơn /s/, năng lượng thấp hơn	Phổ nghiêng về 2–4 kHz
Âm /z/ (hữu thanh của /s/)	Giống /s/ nhưng có năng lượng nền ở thấp tần do dây thanh rung	Thêm dải năng lượng thấp (100–300 Hz)
Nam nói /a/ vs Nữ nói /a/	Giọng nam âm, trầm hơn; giọng nữ sáng hơn	Formant tương tự, nhưng F_0 và độ lệch phổ khác
Đàn guitar vs Violin (nốt La)	Khác nhau ở cấu trúc hài (overtones)	Phổ của violin có hài cao mạnh hơn, âm sắc sáng hơn
Âm /p/ (phụ âm vô thanh bật hơi)	Âm sắc sắc, năng lượng ngắn ở cao tần	Burst noise ngắn ở phổ cao
Âm /b/ (phụ âm hữu thanh tương ứng)	Âm mềm hơn, có năng lượng ở thấp tần	Thêm năng lượng do rung dây thanh

3.2 Phân tích MFCC

Như chúng ta đã phân tích ở phần trước, các đặc trưng âm học của tiếng nói chủ yếu được quyết định bởi tần số cơ bản F_0 và các tần số cộng hưởng formants. Do đó, để khai thác các đặc trưng này, chúng ta tập trung vào việc phân tích phổ tần số của tín hiệu âm thanh.

3.2.1 Biến đổi FFT:

Biến đổi Fourier nhanh (**Fast Fourier Transform** – FFT) là một thuật toán hiệu quả để tính *Biến đổi Fourier rời rạc* (DFT) của một dãy tín hiệu số. Nếu ta có một tín hiệu rời rạc $x[n]$ gồm N mẫu, khi đó DFT của tín hiệu này được định nghĩa như sau:

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j\frac{2\pi}{N}kn}, \quad k = 0, 1, 2, \dots, N-1$$

Trong đó:

- $x[n]$ là tín hiệu trong miền thời gian.
- $X[k]$ là phổ tần số tương ứng tại chỉ số k .
- N là số mẫu của tín hiệu.
- j là đơn vị ảo, với $j^2 = -1$.

Thuật toán FFT giúp giảm đáng kể độ phức tạp tính toán của DFT từ $O(N^2)$ xuống còn $O(N \log N)$ bằng cách khai thác tính chất đối xứng và tuần hoàn của các hệ số mũ phức trong công thức DFT.

Ý nghĩa: Kết quả của FFT, $X[k]$, biểu diễn biên độ và pha của các thành phần tần số có trong tín hiệu $x[n]$. Giải thuật này cho phép chúng ta phân tích chuỗi tín hiệu trong miền tần số.

3.2.2 Biến đổi Fourier ngắn hạn (Short-Time Fourier Transform - STFT)

Nhằm tránh mất mát thông tin, một file âm thanh dài sẽ được chia nhỏ thành các frame có chồng lấp, sau đó ta áp dụng FFT và hàm windowing $w(k)$ cho từng frame. Phép biến đổi STFT của tín hiệu $x(t)$ được định nghĩa như sau:

$$\text{STFT}\{x(t)\}(m, \omega) = X(m, \omega) = \sum_{n=-\infty}^{\infty} x[n] \cdot w[n-m] \cdot e^{-j\omega n}$$

Trong đó:

- $x[n]$: tín hiệu gốc trong miền rời rạc (discrete time signal),
- $w[n]$: hàm cửa sổ (window function), ví dụ như Hamming hoặc Hanning,
- m : chỉ số khung (frame index), đại diện cho thời điểm trong thời gian,
- ω : tần số góc,
- $X(m, \omega)$: biểu diễn phổ tần số của khung m .


Ý nghĩa: Mỗi khung tín hiệu $x_m[n] = x[n] \cdot w[n-m]$ được xem như một đoạn ngắn của tín hiệu gần như tĩnh, do đó ta có thể áp dụng **FFT** cho từng khung để thu được phổ tần số cục bộ. Kết quả là một biểu đồ **phổ thời gian - tần số** (spectrogram), mô tả cường độ năng lượng theo cả hai chiều thời gian và tần số:

$$S(m, \omega) = |X(m, \omega)|^2$$

Mặc dù STFT cung cấp thông tin về cả thời gian và tần số, nhưng nó vẫn có hạn chế trong việc cách con người tiếp nhận âm thanh, khi tai người cảm nhận tần số phi tuyến (nhạy ở vùng thấp 0-1000Hz, kém nhạy ở vùng cao >1000Hz) và cách để phân biệt các âm sắc khác nhau của tai người là tỉ lệ giữa các dải tần.

3.2.3 Mel-Frequency Cepstral Coefficients (MFCCs):

Thang Mel: Là thang cao độ cảm nhận, được người nghe đánh giá và có khoảng cách các quãng bằng nhau. Điểm tham chiếu giữa thang Mel và phép đo tần số thông thường xác định bằng cách gán cao độ cảm nhận 1000 mels cho âm có tần số 1000 Hz. Công thức phổ biến để biến đổi tần số f (Hz) thành m (mels) là:



Hình 3.3: Ví dụ về STFT

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right); \quad f = 700 \left(10^{\frac{m}{2595}} - 1 \right) \quad (3.1)$$

Để trích xuất *Mel-spectrograms*, ta làm theo các bước như sau:

- pre-emphasis: Tăng cường các tần số cao trong tín hiệu âm thanh để cân bằng phổ.
- Sử dụng STFT đối với tín hiệu âm thanh.
- Biến đổi các biên độ thành dB.
- Biến đổi các tần số thành thang Mel.

Pre-emphasis là một bộ lọc FIR (Finite Impulse Response) bậc 1, được áp dụng cho mỗi mẫu tín hiệu:

$$y[n] = x[n] - \alpha x[n-1]$$

Trong đó:

- $x[n]$ là mẫu tín hiệu gốc tại thời điểm n ,
- $y[n]$ là mẫu tín hiệu sau khi áp dụng pre-emphasis,

- α là hệ số pre-emphasis, thường lấy giá trị khoảng 0.95 đến 0.97.

Mục đích chính của bộ lọc này là để cân bằng phổ (spectral balancing) và tăng cường các tần số cao (boost high frequencies).


- Cân bằng Năng lượng Phổ: Tín hiệu giọng nói tự nhiên (đặc biệt là các nguyên âm) có xu hướng có nhiều năng lượng hơn ở các tần số thấp và năng lượng giảm dần ở các tần số cao. Pre-emphasis hoạt động như một bộ lọc thông cao (high-pass filter) để làm phẳng phổ, giúp cho các tần số cao có năng lượng tương đương hơn so với tần số thấp.
- Nhấn mạnh Phụ âm: Các thông tin quan trọng để phân biệt âm thanh (như các phụ âm xát: /s/, /f/) thường nằm ở dải tần số cao. Việc tăng cường các tần số này giúp mô hình nhận dạng tập trung vào chúng tốt hơn.
- Cải thiện Độ ổn định Số học: Việc cân bằng phổ giúp tránh các vấn đề về độ chính xác số học (numerical precision) trong các bước tính toán FFT sau này, vì năng lượng được phân bố đều hơn.

Các bước xây dựng ngân hàng lọc Mel (Mel-filter-banks):

- Chọn số lượng dải Mel (n_{mels}).
- Xây dựng các ngân hàng lọc Mel:
 - Biến đổi tần số thấp nhất và cao nhất thành thang Mel.
 - Tạo các dải Mel cách đều nhau.
 - Biến đổi các điểm đó trở lại đơn vị Hertz.
 - Làm tròn đến gần tần gần nhất.
 - Tạo các bộ lọc tam giác.
- Áp dụng các ngân hàng lọc Mel đối với quang phổ.

$$H_m(k) = \begin{cases} 0 & \text{for } k < f(m-1) \\ \frac{k-f(m-1)}{f(m)-f(m-1)} & \text{for } f(m-1) \leq k < f(m) \\ \frac{f(m+1)-k}{f(m+1)-f(m)} & \text{for } f(m) \leq k < f(m+1) \\ 0 & \text{for } k \geq f(m+1) \end{cases} \quad (3.2)$$

Tham số	Ý nghĩa
$H_m(k)$	Giá trị đầu ra (trọng số) của bộ lọc Mel thứ m tại chỉ số tần số k .
m	Chỉ số của bộ lọc Mel, với $1 \leq m \leq M$ (M là tổng số bộ lọc).
k	Chỉ số bin tần số của kết quả FFT, $0 \leq k < N_{FFT}/2$.
$f(m)$	Chỉ số bin tần số trung tâm (đỉnh tam giác) của bộ lọc thứ m .
$f(m-1)$	Chỉ số bin tần số trung tâm của bộ lọc liền kề trước đó.
$f(m+1)$	Chỉ số bin tần số trung tâm của bộ lọc liền kề sau đó.



Hình 3.4: Mel filter banks

- Tính năng lượng của dải Mel thứ m :

$$E_m = \sum_{k=0}^{N_{FFT}/2-1} |X(k)|^2 \cdot H_m(k)$$

- Sau khi có M giá trị năng lượng E_m , ta lấy logarit của các giá trị này.

$$S_m = \ln(E_m)$$

- Cuối cùng, áp dụng công thức DCT (loại II) lên M giá trị log-năng lượng S_m để thu được các hệ số MFCC. Công thức tính hệ số MFCC thứ n như sau:

$$C_n = \sum_{m=1}^M S_m \cos \left[\frac{\pi n(m-0.5)}{M} \right]$$


- Trong đó, ta thường chỉ giữ lại L hệ số đầu tiên (ví dụ $L = 13$), nên $n = 0, 1, \dots, L-1$.

Tham số	Ý nghĩa
C_n	Hệ số MFCC thứ n .
S_m	Giá trị Log-năng lượng từ bộ lọc Mel thứ m .
M	Tổng số lượng bộ lọc Mel (tổng số tam giác).
m	Chỉ số của bộ lọc Mel (từ 1 đến M).
L	Số lượng hệ số MFCC.

Các hệ số MFCC C_n tính ở bước trước được gọi là hệ số tĩnh (static coefficients). Chúng chỉ mô tả đặc điểm phổ của một khung tín hiệu (frame) tại một thời điểm.

Tuy nhiên, giọng nói là một tín hiệu động (dynamic); cách mà các đặc điểm thay đổi theo thời gian (ví dụ: chuyển tiếp từ phụ âm sang nguyên âm) chứa thông tin nhận dạng cực kỳ quan trọng.

Chúng ta tính toán các hệ số delta (vận tốc) và delta-delta (gia tốc) để nắm bắt thông tin động này.



Hình 3.5: Ví dụ về MFCC, delta và delta-delta

4 Ứng dụng giải thuật

4.1 Tổng quan tập dữ liệu và nhiệm vụ của nhóm:

Tập dữ liệu được sử dụng trong bài toán này là tập dữ liệu Spoken Digit Dataset, bao gồm các mẫu âm thanh của các chữ số từ 0 đến 9 được nói bởi nhiều người khác nhau. Mỗi mẫu âm thanh được lưu dưới dạng file WAV. Tập dữ liệu này bao gồm tổng cộng 17000 mẫu, với mỗi chữ số có 1700 mẫu. Nguồn dữ liệu: <https://www.kaggle.com/datasets/subhajournal/free-spoken-digit-database>

Nhiệm vụ của nhóm là xây dựng mười mô hình HMM để nhận diện chính xác chữ số được nói trong mỗi mẫu âm thanh.

4.2 Thống kê mô tả tập dữ liệu:


Quan sát sơ bộ tập dữ liệu, ta thấy rằng mỗi lớp âm thanh .

4.3 Huấn luyện mô hình HMM


4.3.1 Tập dữ liệu huấn luyện

Tập dữ liệu huấn luyện sau khi trích suất đặc trưng:

- Tổng số chiều (D): 39
- Global Mean (TB của các chiều): -0.0000
- Global Std Dev (TB của các chiều): 1.0000



Hình 4.1: Phân phối của tập dữ liệu huấn luyện sau khi trích suất đặc trưng MFCC



Hình 4.2: Độ dài của tập dữ liệu huấn luyện sau khi trích xuất đặc trưng MFCC

4.3.2 Phương pháp xây dựng mô hình

Tập dữ liệu huấn luyện trên có giá trị liên tục xấp xỉ phân phối Gaussian do đó phương pháp để xây dựng mô hình giải quyết là:

- Tách tập train thành 10 tập tương ứng với 10 chữ số từ 0 đến 9.
- Sử dụng mô hình continuousHMM với hàm phát xạ là hàm Gaussian.
- Sử dụng thuật toán Baum-Welch huấn luyện 10 mô hình tương ứng với các tập.
- Khi kiểm tra, sử dụng hàm Forward để tính xác suất quan sát thuộc về từng mô hình. Lấy mô hình có xác suất cao nhất làm nhãn dự đoán.

4.3.3 Hiện thực hàm huấn luyện mô hình

Khởi tạo tham số đầu vào:

Tham số đầu vào cho hàm huấn luyện bao gồm:

- Số trạng thái ẩn N .
- Số vòng lặp tối đa N_loop
- Ngưỡng hội tụ epsilon

Khởi tạo tham số của mô hình HMM bao gồm:

- Khởi tạo π theo phân phối đều.

```
pi = np.full(num_states, 1.0/num_states)
```

- Ma trận chuyển trạng thái A được khởi tạo theo mô hình left-right 4.5.2 với bậc chuyển trạng thái là 2. Do mô hình tập trung vào giải quyết nhận dạng chữ số, các trạng thái ẩn sẽ được sắp xếp theo trình tự thời gian từ trái sang phải. Mỗi trạng thái chỉ có thể chuyển sang chính nó hoặc hai trạng thái tiếp theo.

```
A = np.zeros((num_states, num_states))
for i in range(num_states):
    stay = 0.6
    move = 0.4
    if i == num_states - 1:
        A[i, i] = 1.0
    else:
        A[i, i] = stay
        A[i, i+1] = move
A /= A.sum(axis=1, keepdims=True)
```

- Tham số mean được khởi tạo ngẫu nhiên theo phân phối chuẩn với mean = 0 và std = 1. Do tập dữ liệu huấn luyện đã được chuẩn hóa.

```
means = np.random.randn(num_states, D)
```

- Tham số covariance được khởi tạo là ma trận hiệp phương sai chéo với giá trị trên đường chéo là phương sai toàn cục của tập dữ liệu huấn luyện cộng một hằng số nhỏ $1e-3$ để tránh trường hợp ma trận không khả nghịch.

```
global_var = np.var(X, axis=0) + 1e-3
covariances = np.zeros((num_states, D, D))
for s in range(num_states):
    covariances[s] = np.diag(global_var)
```

Chạy hàm fit để huấn luyện mô hình

Với hàm `init_params` là hàm khởi tạo ra các tham số ở trên.

```
models = []
for cls_id, cls_name in enumerate(class_names):
    seq_list = [X_train[i] for i, y in enumerate(y_train) if y ==
                cls_id]
    A, pi, means, covs = _init_params(num_states, seq_list)
    model = continueHMM(A=A, means=means, covariances=covs,
                        pi=pi).fit(seq_list, n_loop=n_loop, bound_learning=tol)
    models.append(model)
```

4.3.4 Hiện thực hàm kiểm tra

Sau khi huấn luyện xong 10 mô hình tương ứng với 10 chữ số, ta sử dụng hàm `Forward` để tính xác suất quan sát thuộc về từng mô hình. Lấy mô hình có xác suất cao nhất làm nhãn dự đoán.

```
y_pred = []  
for seq in X_test:  
    scores = [m.forward(seq)[0] for m in models]  
    y_pred.append(int(np.argmax(scores)))
```


4.4 Đánh giá mô hình

Sau khi huấn luyện mô hình HMM và kiểm tra trên tập dữ liệu test, ta thu được kết quả như sau:

Tổng Kết Kết Quả

- Accuracy (Global): 0.9271
- Precision Macro: 0.9285
- Precision Weighted: 0.9285
- Recall Macro: 0.9271
- Recall Weighted: 0.9271
- F1 Macro: 0.9271
- F1 Weighted: 0.9271

Ma Trận Nhầm Lẫn



Hình 4.3: Ma trận nhầm lẫn của mô hình HMM trên tập dữ liệu kiểm tra

Báo Cáo Đánh Giá Chi Tiết

Bảng 4.1: Báo cáo đánh giá chi tiết

Lớp	Precision	Recall	F1-Score	Accuracy	Correct	Support
zero	0.94	0.92	0.93	92.06%	313	340
one	0.93	0.95	0.94	95.00%	323	340
two	0.90	0.93	0.92	93.24%	317	340
three	0.95	0.94	0.95	94.41%	321	340
four	0.93	0.96	0.94	95.59%	325	340
five	0.95	0.95	0.95	94.71%	322	340
six	0.97	0.85	0.91	85.29%	290	340
seven	0.87	0.94	0.90	94.41%	321	340
eight	0.95	0.91	0.93	90.88%	309	340
nine	0.89	0.91	0.90	91.47%	311	340
accuracy			0.93			3400
macro avg	0.93	0.93	0.93			3400
weighted avg	0.93	0.93	0.93			3400

4.5 Kết luận

4.5.1 Ưu điểm

- Mô hình HMM với hàm phát xạ Gaussian phù hợp với bài toán nhận dạng chữ số sử dụng dữ liệu liên tục.
- Kết quả đạt được khá tốt với độ chính xác trên 92%.
- Hiện thực mô hình bằng numpy giúp việc triển khai nhanh chóng và dễ dàng điều chỉnh các tham số của mô hình.
- Mô hình có thể mở rộng để nhận dạng các loại dữ liệu khác nhau bằng cách thay đổi hàm phát xạ.

- Mô hình có thể được cải thiện thêm bằng cách tăng số trạng thái ẩn hoặc sử dụng các hàm phát xạ phức tạp hơn như Gaussian hỗn hợp.
- Mô hình có thể được áp dụng trong các ứng dụng thực tế như nhận dạng giọng nói, nhận dạng chữ viết tay, và các hệ thống nhận dạng mẫu khác.

4.5.2 Nhược điểm

- Mô hình HMM giả định rằng các quan sát là độc lập và tuân theo phân phối Gaussian, điều này có thể không phản ánh đúng bản chất của dữ liệu thực tế.
- Việc lựa chọn số trạng thái ẩn và các tham số khác của mô hình có thể ảnh hưởng lớn đến hiệu suất của mô hình, và việc tìm kiếm các tham số tối ưu có thể tốn thời gian và công sức.
- Mô hình HMM có thể gặp khó khăn trong việc xử lý các chuỗi quan sát dài hoặc phức tạp, dẫn đến hiệu suất kém hơn so với các mô hình học sâu hiện đại.
- Việc huấn luyện mô hình HMM có thể bị ảnh hưởng bởi các vấn đề như overfitting hoặc underfitting, đặc biệt khi tập dữ liệu huấn luyện không đủ lớn hoặc đa dạng.
- Mô hình HMM có thể không hiệu quả trong việc xử lý các dữ liệu có nhiều biến động hoặc nhiễu, dẫn đến kết quả nhận dạng không chính xác.

Tài liệu tham khảo

[1] L. R. Rabiner, 1989, "*A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition*," Proceedings of the IEEE.